BookRec — тестілеу нәтижелерін қорғауға арналған толық түсіндірме

5-қатысушы: Testing, Evaluation & Documentation. Дереккөз: books.csv негізінде орындалған bookrec_testing.py тәуелсіз тесті және нәтижелік CSV файлдары.

1. Тестілеуді қалай орындадым?

1. GitHub репозиторийінен books.csv файлын жүктеп, bookrec_testing.py скриптімен бір папкаға орналастырдым.
2. Windows CMD терминалын сол папкадан ашып, pip install pandas numpy scikit-learn командасын орындадым.
3. python bookrec_testing.py командасын іске қостым. Нәтижелер bookrec_test_results папкасына жазылды.
4. Скрипт кітап атауы, авторы, сипаттамасы және жанры негізінде мәтіндік белгілерді құрастырды.
5. TF-IDF әр кітапты сандық векторға айналдырды; cosine similarity векторлардың ұқсастығын есептеді; ең ұқсас 5 кітап таңдалды.

2. TF-IDF және Cosine Similarity деген не?

TF-IDF — мәтіндегі таңбалар тізбектерінің маңызын санмен көрсететін әдіс. Кодта TfidfVectorizer(analyzer="char_wb", ngram_range=(2,5)) қолданылды: сөз шекарасындағы 2–5 таңбалық бөліктер есепке алынды. Бұл қазақша мәтіндегі ұқсас сөз пішіндерін салыстыруға мүмкіндік береді.

Cosine Similarity екі вектордың бағыттарының ұқсастығын өлшейді. Мәні жоғары болған сайын мәтіндік ұқсастық көбірек. Скрипт бастапқы кітаптың өзін нәтижеден алып тастап, ең жоғары ұқсастық көрсеткен 5 кітапты таңдады.

3. Үш нақты тест және Precision@5

Precision@5 = бастапқы кітаппен бір genre_group санатына жататын ұсыныстар саны / 5. Бұл жерде «сәйкес» деген сөз оқырманның ұнатуын емес, каталогтағы жанр тобының бірдей болуын білдіреді.

Кіріс кітабы	Сәйкес ұсыныс	Precision@5
Абай жолы: 1-том	5 / 5	100%
Ақбілек	5 / 5	100%
Менің атым Қожа	5 / 5	100%

Мысалы, «Абай жолы: 1-том» үшін «Абай жолы: 2-том», «Абай жолы: 3-том», «Абай жолы: 4-том», «Жетім», «Қилы заман» ұсынылды. Бесеуінің genre_group мәні «роман_повесть_әңгіме». Сондықтан 5/5 = 1.0 = 100%.

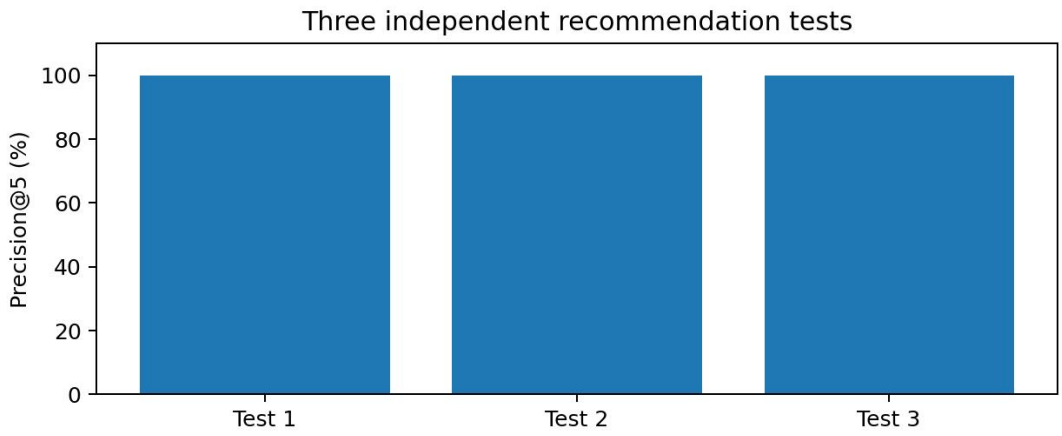
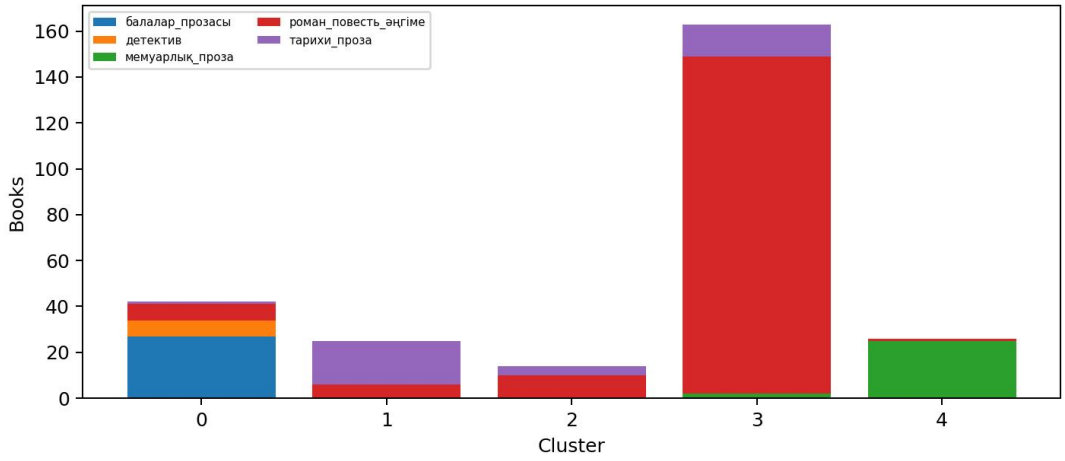


График қалай жасалды: precision_at_5.csv файлындағы үш кітап пен precision_at_5 мәндері алынып, бағандық диаграммаға түсірілді. Үш баған да 100%-ға тең, себебі үш тестте де 5/5 сәйкестік тіркелген.

4. K-Means кластерлеу және екінші график

K-Means — алдын ала кластер атауларын бермей, ұқсас объектілерді топтайтын бақылаусыз оқыту әдісі. Скрипт каталогтағы жанр топтарының санына қарай k=5 таңдады, random_state=42 және n_init=10 параметрлерін қолданды. Модель TF-IDF векторларын бес кластерге бөлді.



Бұл график cluster_distribution.csv кестесінен жасалды. Әр баған — кластер, ішіндегі бөліктер — жанр топтары бойынша кітап саны. Мысалы, 0-кластерде 27 балалар прозасы, 7 детектив, 7 роман/повесть/әңгіме, 1 тарихи проза; 3-кластерде 147 роман/повесть/әңгіме, 14 тарихи проза, 2 мемуарлық проза; 4-кластерде 25 мемуарлық проза және 1 роман/повесть/әңгіме бар.

5. ARI және Silhouette Score қалай есептелді?

Adjusted Rand Index (ARI) = 0.5924. Скрипт K-Means тапқан кластерлерді books.csv файлындағы genre_group белгілерімен салыстырды. 1 — толық сәйкестікке жақын, 0 — кездейсоқ сәйкестік деңгейі. 0.5924 — белгілі бір сәйкестік бар, бірақ толық емес.

Cosine Silhouette Score = 0.1056. Ол әр кітаптың өз кластеріне қаншалықты жақын және өзге кластерлерден қаншалықты алыс екенін бағалайды. 1-ге жақын болса — айқын бөліну; 0-ге жақын болса — кластерлер араласқан. 0.1056 — бөліну әлсіз екенін көрсетеді.

Маңызды: ARI мен Silhouette нәтижелері K-Means топтастыруын сипаттайды; олар сайттағы ұсыныстардың Precision@5 көрсеткішімен бірдей нәрсені өлшемейді.

6. Қате жағдайы және шектеулер

Қате жағдайы: скрипт каталогта жоқ «БұлКітапКаталогтаЖоқ_12345» атауын іздеді. Дәл сәйкестік табылмады — True. Бұл деректердегі атауды іздеу тесті; сайттың пайдаланушы интерфейсіндегі қате хабарламасын тексеру емес.

- Үш тестте ұсынылған 15 кітаптың барлығы бастапқы кітаптардың авторларынан: авторға тәуелділік жоғары болуы мүмкін.
- Precision@5 тек жанр тобының сәйкестігін өлшейді, оқырман талғамын, әртүрлілікті немесе ұсыныстың сапасын толық бағаламайды.
- Silhouette 0.1056: кластерлер әлсіз ажыратылған.
- Бұл тәуелсіз TF-IDF тесті, негізгі сайттың recommender.py функциясының нәтижелері емес.
- Pandas4Warning: fillna('') алдында деректер түрлерін үйлестіру керек; бұл орындалуды тоқтатпаған.